OPENACM

ASSISTANT

参赛技术报告

本地大模型驱动的近似存内计算电路设计与两级探索系统

V1.0 · 2026 年 10 月 25 日

代码基准 8566e1a

语言驱动设计 / 两级协同探索 / 实测证据闭环

摘要

近似数字存内计算将算术精度与电路硬件代价联系起来，其设计评估涉及压缩器组合、存储阵列组织、晶体管尺寸以及多种 EDA 工具。传统脚本流程要求使用者反复转换需求、修改配置、启动仿真并核对报告，容易发生测试条件遗漏、优化层级混杂和历史结果误用。针对这些问题，本作品在 OpenACM 电路生成与评价内核之上，构建本地 DeepSeek 驱动的交互式设计助手，将自然语言需求转化为受校验的实验规格，并在独立副本中执行设计、仿真、验收和结果整理。

系统以精度约束下的两级协同优化为研究主线：近似乘法器通过原生 8/16 位 PEA-GNN 及可选搜索策略筛选压缩器组合，再进行 RTL、综合、STA 活动功耗与单元器件真值复核；SRAM 首先在固定容量和输出字宽下搜索 bank 组织，再固定入选组织开展尺寸及明确 PVT/Monte Carlo 评价。连续对话、证据驱动总结和模型无关的持久经验库贯穿上述过程。

现有小预算验证已覆盖 SRAM 两级流程、8/16 位近似乘法器、真实 DeepSeek 架构选点及不达标负例。8 位参考候选在 4096 组固定种子测试中 MRED 为 0.013639，在指定 5ns 活动周期及 10fF 负载下，综合后 STA 动态功耗与延迟的乘积为 63.1575fJ。相关任务均通过 2631 个原始 OpenACM 文件的完整性核验。现阶段成果证明工程流程能够执行与追溯；不据此宣称 LLM 优于其他优化器、完成论文全部实验或达到工艺签核。

关键词： 本地大语言模型；近似存内计算；OpenACM；设计空间探索；PEA-GNN；两级优化；证据追溯

阅读导航

1. 研究背景与作品定位
2. OpenACM 内核与本作品的关系
3. 总体架构与连续交互
4. 两级设计空间探索方法
5. 可靠执行与证据管理
6. 持久经验与公开数据
7. 实验设置与验证结果
8. 核心亮点与应用价值
9. 部署、演示与复验
10. 当前边界与后续研究
11. 总结
12. 参考资料与证据索引

1 研究背景与作品定位

1.1 研究对象

数字存内计算（Digital Compute-in-Memory，DCiM）通过将存储与计算靠近，减少数据搬移。近似计算进一步允许在明确的应用误差预算下，使用较低硬件代价的算术电路。一个候选设计是否值得采用，取决于其计算误差、功耗、性能、面积以及工作条件，不能仅由某一项指标或生成成功与否决定。

本报告以用户提供的 DATE.pdf 和 DAC.pdf 为研究依据。前者介绍 OpenACM 的 SRAM 近似 DCiM 编译和评价基础；后者提出 OpenACMv2 中的精度约束协同优化（ACCO），强调架构搜索与晶体管尺寸优化的层级关系。[1][2] 本作品在此基础上增加本地语言交互、可信执行、搜索调度和经验复用能力。论文中的性能提升数字不作为本作品的本机实测结果。

1.2 面临的工程问题

问题	具体表现	本作品的处理方式
需求与脚本之间存在转换成本	位宽、压缩器、容量、PVT 和误差阈值分散在不同文件	将需求整理成结构化实验规格，进行类型、单位、范围和组合校验
多工具流程难以连续操作	生成、SPICE、RTL、综合与时序分析各有入口	由外部执行器编排，按任务保存输入、工作副本、日志和报告
搜索变量与评价层级混杂	在固定小阵列上混合调整供电、尺寸和外围，却解释为 bank 优化	区分架构级与器件级，显式固定容量、入选结构和评价条件
模型回答缺少验收依据	将预测值、旧结果或模型的“已达标”文字当作测量	用真实工具结果判断约束，预测、估算与实测分别标记
历史经验难以复用	数值保留在零散报告中，条件与版本容易丢失	建立带来源、环境和修订的本地经验库，并提供 JSONL 交换接口

1.3 作品范围与贡献归属

本作品定位为“面向近似 DCiM 研究的本地智能设计与探索助手”。其主要贡献是把既有电路生成、评价及优化能力组织成连续、可校验、可追溯的实验流程。OpenACM/OpenYield 中的编译器、网表、模型、PEA-GNN 权重及原 NSGA-II 算法来自原工程；本作品不将这些基础能力列为自行提出的新算法。

本作品新增的实现包括统一设计对话、规格约束与预算管理、两级流程隔离适配、候选和父子关系记录、实测验收与中文总结、持久经验及公开数据参考接入。当前 LLM 从受校验的有限候选中选择实验，不直接生成并执行任意程序，也不修改 OpenACM 内置代码。

2 OpenACM 内核与本作品的关系

2.1 内核承担的基础能力

本报告中的“内核”指 OpenACM 电路编译与评价核心，不指操作系统内核。OpenACM 将乘法逻辑、存储模块及 PE 集成到一套可配置流程中，为上层助手提供真实的电路和工具调用对象。

内核模块	主要作用	与助手的衔接
乘法器编译器	生成精确、可配置近似和对数乘法 RTL；近似类型由各压缩位置的选择控制	助手设置位宽、类型、位置分配和输入测试，再调用原生成器
SRAM 电路编译与测试平台	根据阵列、6T 器件和外围配置生成 SPICE，评价读写与 SNM	助手生成任务内配置，调用 Xyce，提取有效样本和保守统计
SRAM 行为级与 PE 编译器	生成存储行为、控制及乘法器集成 RTL	助手选择 PE 尺寸、存储实现和验证流程，检查实际接口行为
数字物理流程	使用标准单元、参考宏及工具脚本完成综合与后端评价	助手适配并校验阶段结果，保存时序、DRC、面积与活动功耗证据
研究优化资产	原生 8/16 位 GNN、压缩器尺寸模板及多种优化研究实现	当前助手隔离接入 PEA-GNN、逐组宽度接口和原 NSGA-II；其他算法不自动视为可用

需要区分两条 SRAM 路径：行为级 SRAM RTL 用于功能及 PE 集成；晶体管级 SRAM SPICE 用于电路评价。行为级仿真通过不能证明 6T 单元电路达标，SPICE 中的尺寸变化也不会自动更新 PE 后端使用的参考宏 Liberty/LEF。

2.2 上层助手与内核的接口边界

OpenACM 原目录保持只读。助手按任务复制普通文件、生成独立参数配置，并调用原工程能力。执行产生的 RTL、SPICE、模型副本、波形和报告均进入任务目录；不在原目录启动生成器，不使用可写硬链接来共享原文件。

OpenYield 提供 SRAM 组织构造和面积模型。本作品复用其实际源代码副本，同时通过显式容量配置避免沿用旧实验脚本中的硬编码容量。原工程存在某项脚本，不等于其已成为本作品的可用入口；当前实际支持范围由校验器、适配器和验证证据共同确定。[3][4]

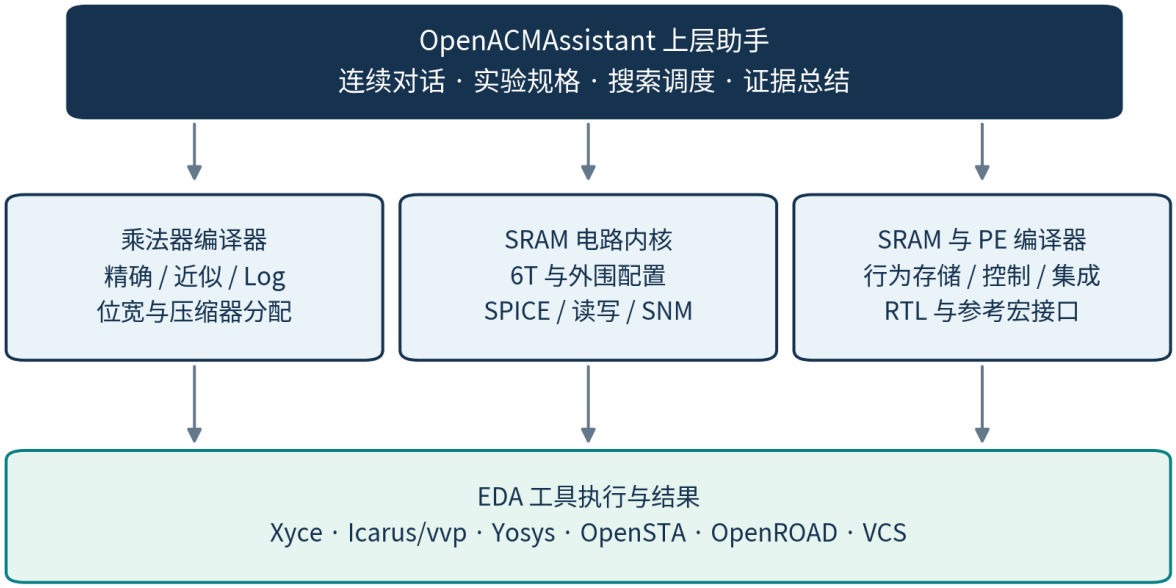


图 1 OpenACM 内核与上层智能助手的关系

3 总体架构与连续交互

3.1 分层架构

系统包含交互与模型层、规格与调度层、隔离执行层及证据与经验层。模型理解用户问题并组织决策，校验器决定配置是否可执行，EDA 提供电路结果，证据层负责验收与追溯。

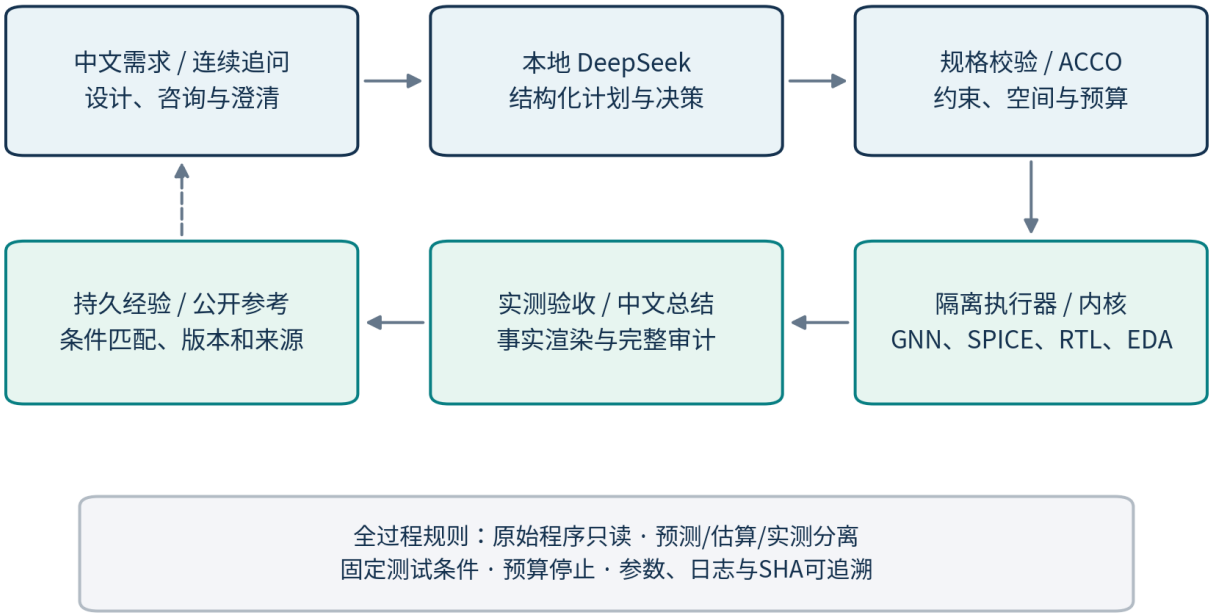


图 2 从语言需求到实测反馈的系统架构

层次	关键实现	职责
交互与模型	assistant.py、conversation.py、领域 skill	连续理解能力咨询、规格补充、解释、执行和结果追问
规格与调度	spec.py、bindings.py、acco_spec.py、acco.py	显式字段绑定、两级实验契约、预算、候选选择、阶段父子关系
隔离与工具	guard.py、worker.py、acco_models.py、acco_physics.py	写隔离、原工程适配、SPICE、RTL、综合、STA 与器件功能检查
证据与经验	result_summary.py、experience.py、public_dataset.py	结果验收、事实驱动摘要、观测修订、条件匹配和外部参考

3.2 统一连续对话

系统维护聊天上下文、当前设计、待澄清需求、尚未执行的草案及最近真实任务。解释性问题与设计需求共享上下文，不要求用户切换到独立的“咨询模式”或“执行模式”。例如，“已有探索结果能做什么”可衔接配置比较、Pareto 分析与复测；“解释最佳配置，然后复测”可在一轮中先说明已有事实，再启动明确的验证。

缺少规格时，系统保留原始需求，并把下一轮补充并入同一实验。对 SRAM 两级探索，必须明确总容量和输出字宽，不能用默认 16×8 阵列替代容量。通过/plan 得到的草案不算实测结果；用户要求开始运行后，执行器使用保存的完整实验配置。

3.3 从自然语言到可执行规格

规划接口使用受约束 JSON，顶层包含电路类型、参数、验收约束和可选目标。两级入口进一步记录架构域、器件域、分阶段预算及物理条件。明确参数由规则与 Schema 共同固定，防止模型把“全 sabetz”换成其他压缩器，或将阈值只写入解释文字。

输入参数、硬约束与排序目标分别表达。例如，“8 位”是结构输入，“MRED≤0.02”是验收条件，“PDP 最小”是排序目标，“预算 64 个候选”是资源限制。未给出性能阈值时，模型不得自行添加。模型输出截断或未通过校验时只恢复一次；持续无效则停止，保留诊断而不启动仿真。

4 两级设计空间探索方法

4.1 实验契约与预算

将一项两级实验表示为：电路基线、架构搜索域、器件搜索域、硬约束、分阶段目标、PVT/测试条件和预算。架构变量描述结构；器件变量描述入选结构中的尺寸；二者在不同阶段求解。

配置字段	含义	关键约束
plan	同一电路的普通单点基线	不含独立 sweep，电路类型需一致
architecture_space	bank 组织或逐位置压缩器类型	不混入器件尺寸，满足容量或拓扑要求
device_space	SRAM 宽度/外围倍率，或压缩器分组宽度倍率	固定入选架构和逻辑功能；不自动改变沟道长
architecture / validation	架构评价与乘法器复核上限	代理评价与真实复核分别计数
shortlist / device_per_parent	入选父项数及各父项或单元的器件预算	包括同条件 baseline；不能等同底层 SPICE 调用总数
max_seconds	整管线墙钟预算	超时保留已执行阶段，标记 incomplete

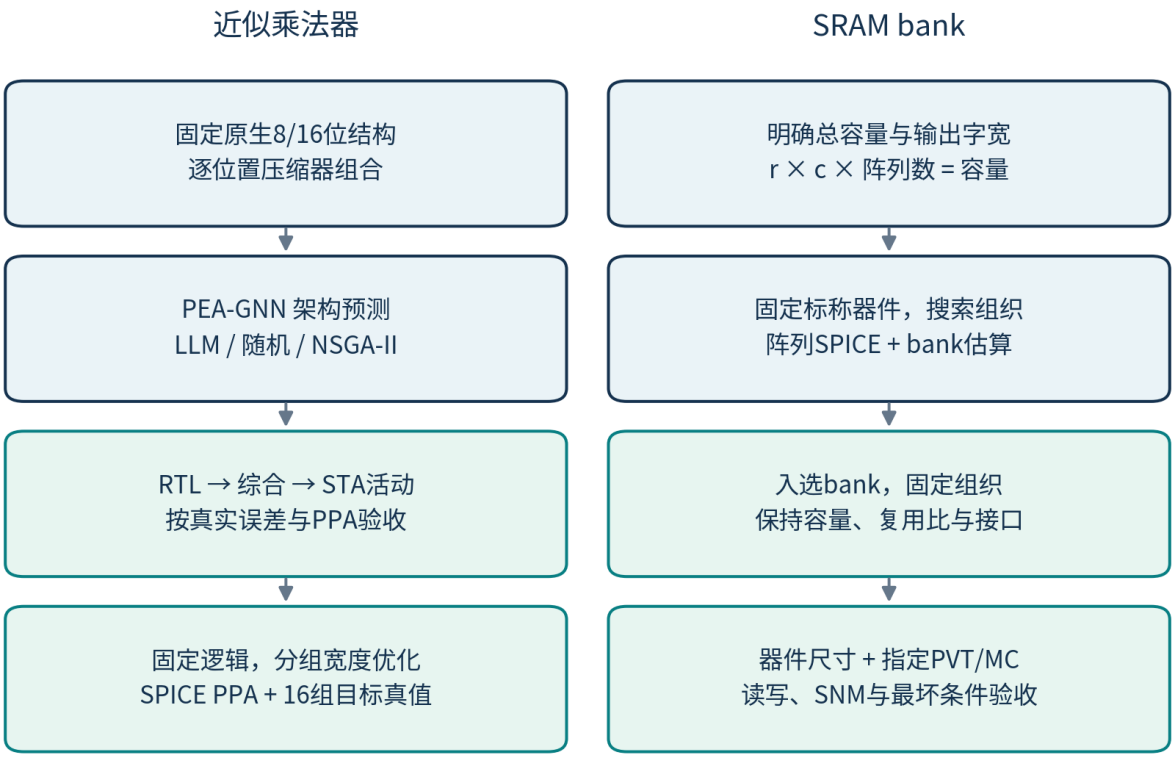


图 3 两类电路的两级探索与验收路径

4.2 近似乘法器架构级

在固定原生压缩树中，以配置向量 x=(c1,...,ck)描述每个可近似位置的类型。当前 8 位有 9 个位置、16 位有 49 个位置，每个位置可选 8 种已有类型。仅 8 位的完整组合数即为 8^9=134,217,728，穷举所有架构通常不合适。系统保留位置顺序，并通过 16 组压缩器真值核对助手编号与 GNN 特征编号。

PEA-GNN 输出 MRED、NMED、延迟、面积和功耗预测。系统核对标签反归一化文件和单位，记录权重与图辅助代码 SHA256；原功耗尺度由 W 换算为 μW。架构阶段默认以预测 PDP 和 MRED 形成目标，明确的误差约束参与筛选。预测字段统一使用 predicted_前缀，不能进入实测验收。

压缩器编号或图结构与模型训练范围不一致，会导致预测失去意义。因此已有 GNN 只用于原生 8/16 位近似结构；其他尺寸可使用已有单点或局部验证适配器，不能直接外推该权重。

4.3 入选项的真实复核

入选配置重新生成 RTL，并使用独立无符号精确乘法参考计算误差。当前 MRED 排除精确参考为 0 的项，NMED 按最大无符号乘积归一化：

```
MRED = mean(|y_hat - y| / y), 仅统计 y ≠ 0 的测试项
NMED = mean(|y_hat - y|) / (2^n - 1)^2
PDP[fJ] = P_dynamic[μW] × D_STA[ns]
```

随后使用 Nangate45 typical 库完成综合，逐向量进行门级与 RTL 对照，再运行 OpenSTA 延迟和 VCD 活动功耗分析。输入活动周期与配置时钟保持一致，明确输出负载，并要求存在有效活动标注。这里的“实测”指实际运行仿真与 EDA 工具得到的模型结果，不是流片后的硅片测量。

误差、PDP 及其他已支持约束在复核后统一判断。即使预测可行，或算术误差通过，只要实际 PDP 越界，就不能进入可推荐集合。预测与实测差异独立保存；条件未完全对齐时，不将该差值直接称为 GNN 同分布测试误差。

4.4 乘法器器件级

对已通过架构实测约束的候选，使用原压缩器模板的共享晶体管分组，分别调整各组宽度。当前尺度域允许原宽度的 0.5–2 倍，并继续检查模板的绝对宽度范围；保持逻辑结构及沟道长。

每个尺寸候选都运行 SPICE PPA 评价，并用 16 组输入检查电压输出是否符合该近似压缩器本身的目标真值。近似逻辑的功能保持约束，不是强制它变成精确压缩器。当前模板使用简化 LEVEL_1 模型，逻辑电平核验采用 VOL≤0.24V、VOH≥0.96V 及 1.2V 供电。失败或电平不合法的候选不参与推荐。

该阶段保存分组宽度、单元 PDP 和面积估算。定制单元尚未重新表征为 Liberty 并回灌完整乘法器或 PE，因此器件阶段收益只在该单元模型范围内成立，不能与综合后架构 PPA 混为同一条优化曲线。

4.5 SRAM 架构级：固定容量的 bank 组织

SRAM 架构表示为(r,c,μ,N)，分别为行数、列数、列复用比和阵列数量，并满足：

```
r × c × N = C_total_bits
N 必须为整数；当前实际电路支持 μ ∈ {1, 2}
```

总容量和输出字宽是独立规格。若单阵列输出不足一字，系统记录序列化周期，并在模型中计入延迟；不把不同吞吐条件视为相同接口性能。架构阶段固定标称器件及 PVT，评价不同组织。

bank 评价采用明确的混合模型：单阵列功耗与延迟来自 SPICE，面积复用 OpenYield 模型，片选与 bank 复用代价采用解析估算。未激活阵列主要按漏电计入，不能将整个动态功耗简单乘阵列数；已经在阵列 SPICE 内的 2 路列 MUX 也不重复增加。bank 相关数值保留_estimate 后缀。

定义 Pmax=max(Pread,Pwrite)，Dmax=max(Dread,Dwrite)。架构 FOM 采用论文对应形式，并固定 W、m²、s 单位：

```
FOM_arch = -log10(Pmax × sqrt(A_bank) × Dmax)
```

FOM 越大越好。单位约定改变会影响对数值，因此跨实验比较前必须统一单位、接口、容量及外围模型。

4.6 SRAM 器件级与鲁棒性

对入选组织固定 r、c、μ 和 N，调整 PU、PD、PG 或已开放的外围宽度倍率。每个候选按相同的明确 PVT 案例、随机种子和 MC 预算运行读写及 hold/read/write SNM。

实现使用原器件模型参数 vth0、u0 和 voff 的均值，按绝对均值乘相对标准差生成高斯样本。vth_std=0.05 表示相对 5%，不是“0.05V 阈值电压标准差”。读写测试为阵列内 6T 单元构造参数样本；SNM 针对目标 bitcell。这是当前实现的统计假设，不能据少量样本推断整宏良率。[4]

跨角评价对功耗、延迟取最坏值，对 SNM 取最小值，再重新计算 FOM。当前默认工程鲁棒 FOM 为：

```
FOM_robust = log10(SNM_min / (Pmax × sqrt(A_bank) × Dmax))
```

该式是本助手采用的工程定义；DAC 提供了鲁棒性优化思路，未给出此唯一显式公式，不能将其归为论文原式。SPICE 失败、无效测量或非正 SNM 均不能作为达标点。

4.7 搜索策略、排名与停止规则

当前可选策略为 LLM、固定种子随机和隔离副本中的原 NSGA-II。LLM 从程序生成的合法候选菜单选择，决策请求、回复和选择均留档；服务不可用时回退为随机并明确标记 random_fallback。用户可为架构与器件分别选择求解器。

搜索缓存重复配置，按唯一候选控制评价预算。原 NSGA-II 小种群可能出现重复初始点，适配层对初始种群去重，并增加提案数和外层时间限制，避免无效循环；原算法文件保持不变。

有效候选先通过硬约束，再计算 Pareto 非支配集合。列表中的“最佳”按配置目标顺序进行字典序排序，不能解释为唯一的多目标最优解；Pareto 集合保留其他权衡。所有最优结论只针对本次实际评价过的候选。策略优劣仍需同空间、同条件、同预算和多种子实验验证。

5 可靠执行与证据管理

5.1 无 sudo 隔离执行

系统运行于普通用户权限下的 Linux x86_64 环境，采用 Landlock ABI≥3 限制仿真子进程的文件写入。任务副本、缓存、临时目录和工具产物集中到当前 run；仅保留/dev/null、/dev/tty 等必要设备写入例外。读和执行能力仍用于访问已安装工具。该机制是文件写隔离，不等同完整网络隔离或容器化部署。

父子进程继承写限制；隔离能力不可用时拒绝无保护执行。运行前后对 OpenACM 原始非 Git 文件进行清单与 SHA 核对。复用的 OpenYield 文件另以 reference_manifest 记录哈希；此处不将部分复用文件核验夸大为整个 OpenYield 目录核验。

5.2 状态与验收分离

状态或证据	含义	不应推导出的结论
prediction	已运行代理推理	用户指标已实测达标
completed	所记录流程完成，具体约束需结合任务结果	全局最优、全输入正确、IEEE 合规或工艺签核
infeasible	已有评价显示约束未全部满足	整个设计空间都不存在可行解
unverified_constraints	缺少对应指标的有效测量	可忽略该约束继续宣布达标
incomplete / failed	预算中断或执行异常	已完成全部阶段或可用预测补齐缺失结果

每个数值同时关联配置、测试分布、库、时钟/活动、PVT 及证据种类。数组 SPICE、bank 估算、综合后 STA 和单元 SPICE 分别保存，禁止跨层级填充指标。

5.3 证据驱动的中文总结

仿真结束后，执行器从结果文件构造可信事实和必须呈现的结论。DeepSeek 可选择事实重点与顺序，数值仍由执行器渲染；未知事实 ID 和虚构建议被拒绝，模型整理失败时回退为实际数据摘要。

摘要直接展示完成状态、最佳已评价项、关键指标、约束是否通过、器件尺寸和使用范围，不要求用户手动查找报告。详细报告、模型整理请求与回复继续保留，便于核对原始证据。

5.4 专属目录与版本追溯

```
OpenACMAssistant/
  app/                    交互、校验、调度、隔离与工具适配
  skills/                 电路领域能力、规则及接口参考
  examples/               可审阅、可复验的实验规格
  runs/<任务>/            工作副本、阶段、波形、日志、报告与完整性
  experience/             SQLite 经验索引及 JSONL 交换文件
  datasets/               带版本和来源的公开参考
  docs/technical-report/  技术报告及图表
```

每次新实验创建新目录，不覆盖历史任务。best_experiment.json 保存 SRAM 最佳完整容量/PVT 配置或乘法器锁定位置分配，best_device_designs 及 widths.json 另存单元尺寸；observations.jsonl 导出阶段观测。完整运行、模型权重、经验和本机配置不进入助手代码仓库。

6 持久经验与公开数据

6.1 本地经验的记录与检索

本地 SQLite 记录完整参数、约束、状态、实际指标、失败原因、源码与执行器指纹、工具环境、数据质量和证据路径。同任务重复导入保持幂等；结果修订保留历史版本；检索优先使用最新可信观测。

经验按电路、尺寸、输入测试、PVT、负载、后端与环境匹配。同范围记录可以作为待复验候选；不同条件、旧数据或外部导入降为参考。历史成功不意味着新任务无须运行，历史失败也不意味着整个类型不可行。

存储和检索接口不依赖 DeepSeek 品牌。标准 JSON/JSONL 可由其他模型的适配器读取，Ollama 兼容模型也可切换后共用经验。这里的“持续学习”是持续积累观测并检索使用，不是自动梯度训练或在线更新权重。

6.2 公开数据的接入与条件核对

项目已归档公开 8 位乘法器数据的固定快照，包含 50,000 个唯一配置、九位置选择和五类标签，并建立来源与本地映射核验。[5] 参考检索只使用本地明确划分的训练部分，验证/测试部分不进入决策上下文；真正重新训练代理模型时，缩放参数应仅由训练集拟合。

公开数据与本地生成及测量条件并未完全一致。已核验的公开样本 40499，其发布 MRED 为 0.01927266，而本地 4096 组、种子 42 的 RTL 复测为 0.0216472906；按 0.02 阈值，前者看似通过，后者不通过。因此公开标签不能替代本地验收，也不能直接并入同条件训练集。

当前接入用于检索参考和候选引入，没有执行 GNN/LLM 权重训练。数据附件保留原许可证声明，不将第三方数据改标为助手代码许可；公开数据条件、单位和来源版本仍需逐项审查。

7 实验设置与验证结果

7.1 验证目的与环境

本报告使用 2026 年 10 月 8 日至 25 日已保存的本机证据，报告生成时重新读取结果与完整性文件，不重新执行大规模搜索。本轮核心两级证据为 2026 年 10 月 25 日的小预算实验；历史 DCiM 后端记录用于说明基础工具链覆盖，不作为器件优化已回灌 PE 的证明。

项目	本报告采用的范围
模型交互	本机 Ollama 中的 deepseek-script；部署说明基于 DeepSeek-Coder-V2 Lite 量化模型，端点与模型名可配置
代理运行	原 8/16 位 PEA-GNN；CPU 推理；Torch 2.6.0 CPU 与 PyTorch Geometric 2.6.1 依赖
数字实测	Icarus/vvp、Yosys、Nangate45 typical 及 OpenSTA；PDP 使用动态功耗
乘法器活动条件	5ns 输入活动周期、10fF 输出负载；种子 42；样本数按各项列出
SRAM 鲁棒性冒烟	64bit 容量、4bit 输出；TT/27℃/1V 及 SS/85℃/0.9V；每角 MC=2，相对标准差 5%
代码和来源	助手提交 8566e1a；原工程具体输入以各任务清单及 SHA 为准

样本数与预算均较小，适用于工程流程验证。尚不具备宣称搜索效率提升百分比、LLM 最优性或统计良率的依据。

7.2 SRAM 固定容量的两级验证

E01 设置 2 个架构评价、1 个入选组织和 2 个器件候选。架构阶段在相同标称条件下比较 4×4×4 与 8×4×2，两者容量均为 64bit，输出字宽均为 4bit。入选 8×4×2 后，仅调整 PD 宽度，其他基线尺寸保持 PU=90nm、PG=135nm、L=50nm。[E01]

阶段及候选	读功耗估算/μW	读延迟估算/ns	SNM 最小值/V	本阶段 FOM
架构：4×4×4，标称 PD135nm	12.293779	0.719823	—	18.557527
架构：8×4×2，标称 PD135nm	13.847376	0.577805	—	18.693364
器件：固定 8×4×2，PD135nm，PVT/MC	13.874822	0.911298	0.155480	17.686300
器件：固定 8×4×2，PD180nm，PVT/MC	13.936617	0.894855	0.169445	17.727078

表中前两行采用 FOM_arch，后两行采用 FOM_robust，不跨阶段比较其数值大小。架构选择没有只按读功耗最小值判断；FOM 同时考虑读写功率、延迟与面积。器件阶段相同 PVT/MC 条件下，PD180nm 相对 PD135nm 的最小 SNM 提高约 8.98%，读延迟降低约 1.80%，读功耗增加约 0.45%，体现了真实取舍。该结论仅对应本次两点及模型条件，不是普遍最优尺寸。

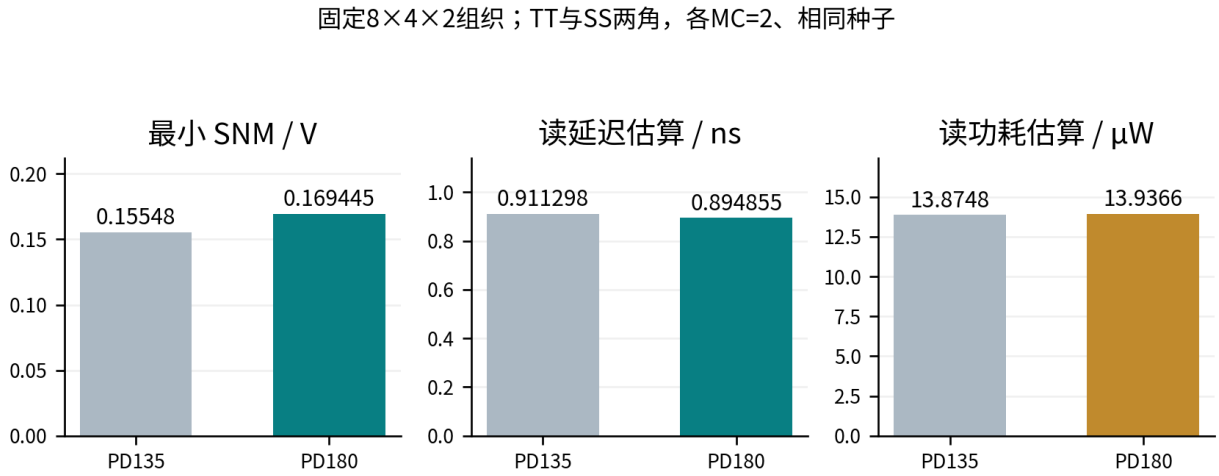


图 4 固定入选 SRAM 组织后的器件取舍

本项共执行 6 个阵列任务：2 次标称架构评价，加上 2 个器件候选各 2 个 PVT 案例。最佳项 bank 面积估算为 648.757583µm²，hold/read/write SNM 分别为 0.3303099V、0.1694452V 和 0.6825216V。该实验未要求 SNM≥0.2V，不能声称已达到此阈值。4KB 示例已提供配置与真实模型计划预览，本报告不将 64bit 冒烟当作 4KB 大规模优化结果。

7.3 8/16 位乘法器两级验证

E02 的 8 位架构阶段实际执行 4 次 GNN 评价，选择 1 项进行 RTL/综合/STA 复核，并执行 2 个单元器件候选；E03 的 16 位流程用于验证另一原生模型及 49 位置结构的接通，架构、入选和器件预算均为 1。[E02][E03]

指标	8 位参考候选，4096 组	16 位参考候选，256 组
MRED	0.0136390362	0.0005626603
NMED	0.0013711373	0.0000191671
与精确结果不同的输入数	2674	224
Nangate45 综合面积/µm²	291.802	1215.354
STA 延迟/ns	0.74663091	1.36742842
指定活动下动态功耗/µW	84.5899522	313.9475160
PDP/fJ	63.1574730	429.3007558
有效活动标注引脚数	909	3731

两项样本数不同，不能直接据 MRED 或 PDP 比较架构优劣；表格展示的是两种位宽的可执行与可追溯性。近似候选存在较高的逐输入错误率，与较小平均相对误差可以同时出现，不能将 MRED 通过写成逐输入无错误。

E05 进一步在固定 8 位 AKbar2 配置上同时施加 MRED≤0.02 与 PDP≤100fJ，实际分别为 0.0136390362 和 63.1574730，均通过。该项保存 best_experiment 和器件最佳记录，并完成自动中文摘要。单元 baseline 为 1.2V 简化 LEVEL_1 条件下，延迟 0.98284ns、功耗 0.6731μW、PDP0.6615496fJ、面积估算 5.4897μm²，16 组目标真值全部通过；这些单元数字不能填入乘法器总体指标。[E05]

7.4 真实 DeepSeek 与负例

验证项	实际现象	说明
真实架构选点 E04	2 次架构评价含 1 次 deepseek 选择，保留 request/reply/selection，未发生随机回退	验证模型接入搜索，不证明其优于随机或 NSGA-II
严格 PDP 负例 E06	同类 8 位候选 MRED 通过，但 PDP≤1fJ 不通过，器件候选 0、无最佳推荐	证明精度通过不能替代 PPA 验收
全 sabetz 负例 E07	固定类型、256 组下 MRED 未满足 0.02，未进入器件优化	尊重用户类型要求，不静默换成容易达标的压缩器
真实计划预览 E08	保留 4KB 容量、8bit 输出、2 候选及分阶段算法	验证完整规格落地；不代表已运行 4KB 搜索
真实结果整理 E09	metadata 中的 model_used=true，数字由可信事实渲染	验证模型组织摘要，避免自由生成测量数值

7.5 历史内核与完整后端覆盖

既有参考流程记录包含 8 位精确乘法器 65,536 对输入穷举、0 错误，以及 16×8 DCiM 的 12 阶段后端。对应 16×8 参考宏、10ns 配置的 setup/hold slack 为 4.64506388ns/0.03318188ns，详细布线 DRC 为 0，路由面积 7800μm²，给定 VCD 活动下功耗 251.239864μW。[E10]

这些结果表明助手能够调用原内核及后端工具链。该 PE 使用原参考宏，不能解释为本报告 SRAM 器件最优点已完成内部版图、重新表征或物理回灌。历史多尺寸验证与浮点特殊值失败均保留在验证记录中；源代码模块名“Exact”不能代替独立功能证明。

7.6 软件回归与源保护

七项基础回归在独立 Git 源码快照、无本机 runs/experience/datasets 且原工程路径不可用的条件下通过，覆盖 14 项实际 Landlock 保护检查、计划恢复、总结事实约束、探索续跑、20,000 组独立 FP32 参考对照、经验修订与检索、公开数据隔离和 23 类对话路由。check_acco 另在具备原参考代码的工作目录验证容量、单位、预测隔离、预算、小种群 NSGA-II 及完整实验复验入口。[E11]

核心两级任务的原始 OpenACM 完整性均为 unchanged=true，核对 2631 个非 Git 文件。小种群初始重复、VCD 切换周期不一致及模型自行添加延迟阈值等问题均曾被验证发现并修正；初版失败记录保留，不混入最终有效结果。

8 核心亮点与应用价值

8.1 面向研究任务的自然语言入口

用户可以在同一对话中咨询能力、补充规格、修改设计、解释结果和启动复验。系统将交流连接到真实工具操作，降低重复手动改配置、找入口和读日志的成本。操作成本的实际减少仍需后续用户任务计时实验量化，不在此虚构效率提升比例。

8.2 LLM、代理模型与优化器分工协作

语言模型负责理解、计划与有限候选决策，GNN 负责快速性能预测，NSGA-II 或随机策略提供可选搜索基线，SPICE/RTL/EDA 负责最终证据。该设计允许替换模型或搜索策略，同时保留统一实验规格和评价接口。

8.3 遵循架构到器件的设计层级

容量约束下的 bank 组织与固定组织后的尺寸调整分开处理；乘法器组合搜索与单元宽度细调也分别建模。系统保留父子关系和同条件 baseline，避免将固定小阵列的局部最优泛化为整个 DCiM 系统优化。

8.4 可追溯的结果与经验复用

每项结论能够关联到任务、输入、源码指纹、工具输出和验收记录。观测以标准接口持续累积，便于跨模型检索、失败分析和后续构建“配置/图结构＋实测指标”的代理训练数据。

8.5 使用价值与适用对象

系统适用于近似算术与 SRAM 研究、数字存内计算实验教学、EDA 工作流演示以及可审计的多策略设计空间探索。普通用户权限和本地模型部署有利于在共享服务器或实验室环境使用。工程数据留在本地的工作方式不等于所有第三方工具与模型均可免费商用；部署仍取决于各依赖及数据的实际许可。

9 部署、演示与复验

9.1 部署要求

需要 Python 3.10+、Linux x86_64 及 Landlock ABI≥3，另行准备只读 OpenACM 源目录和相应 EDA 工具。SRAM bank 模型默认读取相邻 OpenYield 路径，可通过环境变量指定；GNN 附加依赖由 requirements.acco.lock.txt 管理。用户级 Ollama 提供本地模型接口，模型名与地址可切换。无需 sudo，不替换用户现有 Conda 环境。

9.2 建议演示链路

先展示“你能做什么”与能力说明，再预览一项明确的两级实验；运行小预算配置后，直接展示关键指标与验收；最后追问最佳配置，并展示同条件复测和本地经验记录。严苛阈值负例可以证明系统不会因为模型文字积极就宣布成功。

```
./openacm-assistant.sh chat
./openacm-assistant.sh acco --spec examples/acco-sram-smoke.json --plan-only
./openacm-assistant.sh acco --spec examples/acco-sram-smoke.json --without-model
./openacm-assistant.sh acco --spec examples/acco-multiplier-smoke.json --without-model
./openacm-assistant.sh summarize runs/<已完成任务目录> --no-model
./openacm-assistant.sh memory stats
```

without-model 将 LLM 求解器改为随机，原 nsga2 配置仍运行 NSGA-II；不能把该演示写成 DeepSeek 选点。使用真实模型时保留决策审计，再核对是否发生回退。

9.3 复验方法

SRAM 使用保存的 best_experiment.json 复验，以保留总容量、输出字宽、组织、器件及 PVT；不能降为单阵列 run 后宣称相同 bank 实验。乘法器 best_experiment 锁定已验证压缩器位置分配；单元宽度另按 widths.json 复验。完整两级任务当前没有开放中途 resume，旧单级任务仍使用原续跑入口。

代码仓库为 https://github.com/adsays520/OpenACMAssistant，本文对应提交 8566e1a。原 OpenACM/OpenYield、模型权重、EDA 库和完整任务数据不随助手代码发布，需要在复验环境单独准备。仅凭本报告中的表格不能替代完整工作环境。

10 当前边界与后续研究

当前边界	影响	后续工作
仅原生 8/16 位接通已有 GNN	不能用于任意尺寸或新库预测	构建条件完整的多尺寸数据，重新训练并独立测试
SRAM 采用阵列 SPICE＋bank 解析模型	不是完整 bank 晶体管仿真或内部版图结果	校准外围模型，补内部布局与更强物理验证
压缩器模板为 LEVEL_1 且未回灌 Liberty	单元收益不能直接成为整 PE 收益	标准工艺表征、重新综合及后端回灌
PVT/MC 仅覆盖明确案例和有限样本	不能推断稀有失效与宏级良率	扩大条件和样本，验证统计假设及失效模型
PSNR/NN Top-1/Top-5 未自动接通	当前算术误差不能替代应用质量	增加固定应用集和独立精度评价
LLM 选点仅有功能证据	尚无算法优势或加速比结论	相同预算、多种子、公平策略对照与消融

后续策略实验应固定电路域、baseline、代理模型、输入分布、验收约束及时间/调用预算，分别统计可行率、Pareto 覆盖、最优值随预算曲线、真实 EDA 次数和墙钟时间。代理更新或经验检索变化也要作为显式实验因素，避免把额外数据或更多计算量误判为 LLM 决策能力提升。

11 总结

OpenACMAssistant 将本地语言模型与 OpenACM 电路内核连接，形成从需求理解、结构化计划、两级探索到真实工具验收、中文总结与经验积累的工程闭环。已有验证支持“系统能够按明确条件执行并追溯结果”这一结论。作品的主要价值在于研究流程整合、可靠执行和交互式迭代；进一步的算法优越性、应用精度与物理收益仍需通过对应实验建立。

12 参考资料与证据索引

12.1 参考资料

[1] Yiqi Zhou 等：OpenACM: An Open-Source SRAM-Based Approximate CiM Compiler。用户提供 DATE.pdf，主要参考编译架构、SRAM/PE 和评价流程。本文未核验其正式出版年份与版本状态。

[2] Yiqi Zhou 等：OpenACMv2: An Accuracy-Constrained Co-Optimization Framework for Approximate DCiM。用户提供 DAC.pdf，主要参考 ACCO、PEA-GNN 及 SRAM 两级优化。本文不将论文报告提升作为本作品实测。

[3] OpenACMAssistant，提交 8566e1ac9eff28dc668404e10480ef2ac664a70b。代码仓库：https://github.com/adsays520/OpenACMAssistant。

[4] 本机 OpenACM/OpenYield 源文件及助手 app/worker.py、app/acco_models.py、app/acco_spec.py、app/acco.py。各实际复用文件的 SHA 记录于任务 reference_manifest.json；工程边界见 docs/OpenACM 能力与需求指南.md 和 skills/openacm-design/references/acco.md。

[5] 公开数据固定快照：xuzhuo0417/openacm-gnn-8bit-dataset，revision=72a0ad0ea83d5b724999c6c1a66d8e57fda7c1d1。接入、许可与条件核对见 docs/公开数据接入.md；本地经验机制见 docs/持久经验库.md。

12.2 实验与审计索引

以下路径相对于 OpenACMAssistant 根目录。完整本机任务不随报告或 Git 仓库分发；本报告附 evidence_snapshot.json 保存用于表图的配置、指标、状态和文件哈希。

编号	本机证据位置	主要用途
E01	runs/20261025_134117_acco_sram_fb675e	固定容量、PVT/MC 与器件取舍
E02	runs/20261025_132043_acco_multiplier_052c4b	8 位 GNN、原 NSGA-II 与实测
E03	runs/20261025_132307_acco_multiplier_4504d7	16 位原生模型与实测
E04	runs/20261025_132333_acco_multiplier_5f789e	真实 DeepSeek 架构决策
E05	runs/20261025_134246_acco_multiplier_b21791	双约束、器件尺寸及自动摘要
E06	runs/20261025_133552_acco_multiplier_84cbab	精度通过但 PDP 未通过的负例
E07	runs/20261025_132614_acco_multiplier_ae5f8b	固定全 sabetz 未达标负例
E08	runs/20261025_133919_planning_6cad2c	真实 4KB 完整规格计划预览
E09	runs/20261025_134015_acco_multiplier_eff2af/reports/summaries	model_used=true 的真实结果整理
E10	runs/20261010_144501_full_flow_89aabc	历史精确穷举与 16×8 参考 PE 后端
E11	verification/release_regression.json、verification/acco_validation.json	独立发布回归与两级完整性汇总

技术报告日期采用北京时间。表中小数按显示精度舍入，完整数值以附带证据快照及原任务为准；本文没有新增或覆盖原始仿真结果。